



ÉQUIPE DATA

DOCUMENTATION TECHNIQUE

Projet : Analyse de parc d'abonnements

Responsable : Paulianne FONTOURA

Mars, 2025

SOMMAIRE

1. ENVIRONNEMENT MÉTIER	3
1.1 Compréhension du problème et contexte de l'entreprise	3
1.2 Questions et défis	3
1.3 Objectifs de l'analyse et méthodologie	4
2. STRUCTURE DES SOURCES ET PRÉTRAITEMENT	5
2.1 Sources disponibles	5
2.2 Structure des fichiers disponibles	5
2.3 Structure des tableaux des abonnés hebdomadaires (ABO_PM_*)	5
2.4 Structure de la table de référence (referentiel_abonnements)	6
2.5 Points critiques	6
3. MODELISATION ET PRÉPARATION DES DONNÉES	7
3.1 Importation et concaténation des fichiers	7
3.2 Segmentation et normalisation des données	7
4. ANALYSE DESCRIPTIVE	8
5. ANALYSE EXPLORATOIRE	8
5.1 Évolution temporelle des abonnements	8
5.2 Taux de renouvellement des abonnements	9
5.3 Impact des promotions sur les tarifs	10
5.4 Segmentation des clients par fidélité	10
5.5 Répartition des abonnements par tarif mensuel	11
5.6 Corrélation entre type d'offre et nombre d'abonnés	12
5.7 Analyse des valeurs 'Non_trouvé'	12
6. ANALYSE INFERENCIELE	13
6.1 Test du χ^2 pour dépendance catégorielle	13
6.2 Test de Fisher pour la comparaison de proportions	14
6.3 Analyse des tendances avec Theil-Sen et régression linéaire	15
6.4 Modélisation probabiliste du churn avec une chaîne de Markov	15
6.5 Comparaison des nouveaux abonnés vs churn estimé dans le temps	16
6.6 Projection linéaire de la croissance des abonnements	17
6.7 Seuil minimal pour stabiliser la base d'abonnés	18
7. EXPORTATION ET PARTAGE DES DONNÉES	18
8. DATAVIZ LOOKER	19
8.1 KPIs et vue d'ensemble	19
8.2 Séries temporelles	20
8.3 Tableau pour exportation	20
9. STRATÉGIES BUSINESS, SCALABILITÉ ET ACTIONS À VENIR	21
9.1 Collecte de nouvelles données pour enrichir l'analyse	21
9.2 Approfondissement de l'analyse via de nouvelles métriques	21
9.3 Gouvernance et récupération des données	22
9.4 Automatisation et industrialisation	22

1. ENVIRONNEMENT MÉTIER

1.1 Compréhension du problème et contexte de l'entreprise

Paris Match, un acteur majeur du paysage médiatique français, s'appuie sur un modèle économique fortement dépendant des abonnements numériques et physiques. Dans un contexte où la presse subit une mutation rapide avec la digitalisation, l'optimisation de la gestion du parc abonnés devient un enjeu stratégique. L'objectif est d'exploiter les données d'abonnement hebdomadaires fournies par un prestataire via SFTP, d'en extraire des insights opérationnels et de structurer une analyse permettant une meilleure compréhension des comportements abonnés. Cette démarche s'inscrit dans un cadre décisionnel visant à améliorer la fidélisation, à identifier des leviers d'acquisition efficaces et à optimiser les performances des offres commerciales.

1.2 Questions et défis

Dans un marché hautement concurrentiel où la fidélisation des abonnés est aussi cruciale que l'acquisition de nouveaux clients, plusieurs questions stratégiques émergent :

<i>Acquisition</i>	Comment attirer de nouveaux abonnés de manière rentable ? Quels canaux et leviers marketing sont les plus efficaces pour maximiser les conversions tout en minimisant les coûts d'acquisition ?
<i>Engagement</i>	Comment maximiser la durée de vie des abonnés ? Quels facteurs influencent leur engagement et leur propension à rester abonnés sur le long terme ?
<i>Churn et rétention</i>	Comment réduire le taux de désabonnement ? Quelles sont les caractéristiques des abonnés les plus susceptibles de résilier et comment anticiper ces comportements ?
<i>Optimisation des offres</i>	Quels abonnements sont les plus performants en termes de rétention et de valeur à long terme ? Comment ajuster les offres pour maximiser leur rentabilité et leur attrait ?
<i>Pilotage des performances</i>	Quels KPIs permettent de suivre efficacement l'évolution du parc abonnés et d'identifier les tendances critiques à court et moyen terme ?

1.3 Objectifs de l'analyse et méthodologie

L'objectif principal de cette analyse est de produire un diagnostic approfondi du parc abonnés en suivant un processus structuré, garantissant une approche méthodique et exploitable. Le projet se déroulera en plusieurs étapes successives :

1.3.1 Compréhension des sources et prétraitement des données :

Examiner la structure des fichiers fournis, identifier les relations entre les tables et garantir l'intégration cohérente des différentes sources tout en détectant les incohérences et en assurant la qualité des données avant toute exploitation analytique.

1.3.2 Traitement et structuration des données :

Nettoyer et harmoniser les données en traitant les valeurs aberrantes, les doublons et les informations manquantes, puis enrichir les jeux de données en croisant les abonnements avec leurs offres associées afin d'assurer une base analytique robuste et exploitable.

1.3.3 Analyses descriptives, exploratoires et inférentielles :

Décrire et segmenter le parc abonnés en suivant des indicateurs clés, identifier les tendances et comportements via des analyses exploratoires, et exploiter des modèles statistiques pour anticiper le churn et mesurer l'impact des offres sur la rétention.

1.3.4 Production d'un reporting et visualisation sur Looker Studio :

Concevoir des tableaux de bord dynamiques permettant d'explorer les données en temps réel, d'exposer les métriques critiques et de faciliter l'interprétation des résultats grâce à une visualisation stratégique et actionnable.

1.3.5 Évaluation des stratégies et recommandations :

Traduire les insights en recommandations concrètes en matière d'optimisation des offres, d'acquisition et de fidélisation, en mettant en lumière les opportunités d'amélioration et les ajustements nécessaires pour maximiser la valeur du parc abonnés.

1.3.6 Scalabilité et étapes suivantes :

Structurer l'analyse pour une montée en échelle, en intégrant des pipelines automatisés, des mises à jour dynamiques des dashboards et une consolidation des résultats dans un cadre analytique pérenne, garantissant un suivi optimisé et une prise de décision éclairée.

2. STRUCTURE DES SOURCES ET PRÉTRAITEMENT

2.1 Sources disponibles

- Trois fichiers hebdomadaires au format CSV/XLSX représentant l'état du parc abonnés à différentes dates.
- Un fichier de référence listant les types d'abonnement, les offres et les leviers marketing.
- Le fichier référentiel est clés pour relier chaque abonné à son offre via l'identifiant `alias\_oe`.

2.2 Structure des fichiers disponibles

Archive	Description
<code>ABO_PM_20241230.csv</code>	Etat de la flotte d'abonnés dans la semaine du 30/12/2024
<code>ABO_PM_20250106.csv</code>	Etat dans la semaine du 06/01/2025
<code>ABO_PM_20250113.xlsx</code>	Etat dans la semaine du 13/01/2025
<code>referentiel_abonnements.xlsx</code>	Référence pour les offres, campagnes et périodes de test

2.3 Structure des tableaux des abonnés hebdomadaires (ABO_PM_*)

Comportement	Type	Description
4037126	int	ID probable de l'abonné
PMVN	str	Code fixe (identifiant interne possible)
3604	int	Code de l'offre ou statut de l'abonnement
20160207	int	Date (probablement le début de l'abonnement)
PM013	str	Code de l'offre ou de l'état de l'abonnement

2.4 Structure de la table de référence (referentiel_abonnements)

Nom de la colonne	Type	Description
<code>alias_oe</code>	str	ID probable de l'abonné
<code>periode_essai</code>	int	Code fixe (identifiant interne possible)
3604	str	Code de l'offre ou statut de l'abonnement
<code>offre</code>	str	Date (probablement le début de l'abonnement)

2.5 Points critiques

2.5.1 Hétérogénéité des nomenclatures :

L'absence de standardisation dans l'intitulé des colonnes et des tables complique l'intégration et l'automatisation des traitements, nécessitant une harmonisation préalable.

2.5.2 Manque de cohérence sémantique :

Les noms des tables ne suivent pas une logique explicite, rendant difficile l'interprétation intuitive des données et augmentant le risque d'erreurs dans les jointures et analyses.

2.5.3 Absence de dictionnaire de données et de métadonnées :

L'absence de documentation formelle sur les variables et leurs définitions limite la compréhension des relations entre les entités et ralentit l'exploration analytique.

2.5.4 Données incohérentes et clés non exhaustives :

Certaines clés de liaison ne couvrent pas l'ensemble des abonnements, entraînant des pertes d'information et des difficultés dans le rattachement des abonnés aux offres souscrites.

2.5.5 Codification opaque et ambiguë :

L'utilisation de codes alphanumériques non documentés (ex. 3604, PM013) impose un travail de mappage préalable pour établir leur signification et garantir leur exploitation analytique.

3. MODELISATION ET PRÉPARATION DES DONNÉES

3.1 Importation et concaténation des fichiers

L'importation des fichiers commence par le montage de Google Drive afin d'accéder aux données stockées dans un répertoire spécifique. Trois fichiers sont ciblés : deux au format CSV et un au format Excel. Leur lecture est conditionnée à leur extension, avec `pd.read_csv()` pour les CSV et `pd.read_excel()` pour l'Excel, tout en s'assurant que les données sont chargées sous forme de chaînes de caractères. Une nomenclature commune est imposée aux colonnes pour garantir l'uniformité du jeu de données.

Une fois les fichiers chargés, ils sont concaténés en un unique DataFrame (`df_abonnements`) à l'aide de `pd.concat()`, sans conserver les index d'origine pour éviter tout doublon. Ensuite, un fichier de référence contenant les détails des offres (`df_referentiel`) est chargé, ainsi qu'une liste d'exclusion (`df_exclusion`) qui permet d'éliminer les abonnements comportant des `alias_oe` interdits.

Le jeu de données est enrichi en effectuant une première jointure entre `df_abonnements` et `df_referentiel` via `alias_oe`. Si certaines informations restent manquantes, une seconde tentative est réalisée en associant les abonnements via `code_offre`. Afin de garantir la cohérence des données, les `code_tarif` sans correspondance sont identifiés, et les valeurs manquantes sont comblées en utilisant les modalités les plus fréquentes. Si aucune correspondance ne peut être trouvée, elles sont marquées comme `Non_trouvé`. Enfin, une validation est effectuée en affichant un échantillon des données consolidées et en comptabilisant les enregistrements encore incomplets.

3.2 Segmentation et normalisation des données

Cette étape commence par une segmentation des abonnements selon leur type en analysant la colonne `offre`. Une fonction identifie si une offre appartient à une promotion spécifique (PROMO), à une offre continue (FIL ROUGE), ou si elle n'entre dans aucune de ces catégories. Ensuite, une extraction détaillée des tarifs et des périodes promotionnelles est réalisée, permettant d'identifier les valeurs spécifiques de `tarif_initial`, `tarif_post_promo` et `duree_promo_mois` en fonction du texte descriptif. Une seconde fonction détecte si l'abonnement comporte un engagement d'un an ou s'il est sans engagement.

Une fois la classification effectuée, les données temporelles sont traitées : la colonne `date_debut` est convertie en format `datetime`, et `periode_essai` est transformée en valeur numérique. Ensuite, le tarif total estimé est calculé en tenant compte de la période promotionnelle et des jours restants facturés au tarif standard. Ce calcul assure une estimation précise du coût réel d'un abonnement en fonction de sa durée effective. Une correction finale est appliquée pour éviter les écarts de quelques centimes dus aux arrondis.

Les colonnes du DataFrame sont réorganisées selon une structure cohérente, garantissant une lecture fluide des informations. Une vérification finale est effectuée en affichant un échantillon des données traitées, permettant de confirmer la bonne application des transformations.

4. ANALYSE DESCRIPTIVE

4.1 Structure des données

L'analyse commence par une distinction entre les colonnes quantitatives et qualitatives à l'aide des types de données détectés (`np.number` pour les variables numériques, tout autre type étant considéré comme qualitatif). Ensuite, une recherche systématique des valeurs aberrantes est effectuée pour les variables numériques en appliquant la règle de Tukey. Cette méthode repose sur l'intervalle interquartile (IQR), défini comme la différence entre le troisième quartile (Q3) et le premier quartile (Q1). Une valeur est considérée comme aberrante si elle est inférieure à $Q1 - 1.5 * IQR$ ou supérieure à $Q3 + 1.5 * IQR$. Pour chaque variable quantitative, ces seuils sont calculés et les valeurs extrêmes identifiées. Si une modalité

aberrante est détectée dans une variable, sa valeur dominante (`mode()`) est enregistrée, sinon, elle est notée comme absente.

Parallèlement, une analyse des variables qualitatives est menée pour identifier les modalités rares. Une modalité est considérée comme rare si sa fréquence est inférieure ou égale au 5^e centile de la distribution des fréquences. Ces valeurs peu fréquentes sont recensées pour chaque variable catégorielle et notées dans un dictionnaire.

Une fois ces détections effectuées, un tableau récapitulatif est construit avec plusieurs indicateurs :

- Nombre total d'observations (`df_final.count()`) pour quantifier les données disponibles.
- Nombre de valeurs uniques (`df_final.nunique()`) pour mesurer la diversité de chaque variable.
- Modalité la plus fréquente (`df_final.mode().iloc[0]`), identifiant la valeur dominante pour les variables qualitatives.
- Fréquence absolue de cette modalité (`df_final.apply(lambda x: x.value_counts().iloc[0])`) indiquant combien de fois cette valeur apparaît.
- Fréquence relative en pourcentage (`df_final.apply(lambda x: (x.value_counts().iloc[0] / len(x)) * 100)`) pour évaluer l'importance de la modalité dominante.
- Valeurs aberrantes et modalités rares (`{**outliers_valeurs, **valeurs_rares}`), fusionnant les détections réalisées sur les variables quantitatives et qualitatives.

Ce tableau est affiché pour validation, permettant ainsi de visualiser la distribution des données et d'identifier les éventuelles anomalies.

4.2 Mesures de centralité et de dispersion

Ensuite, différentes mesures de centralité et de dispersion sont calculées pour les variables essentielles telles que le nombre d'abonnés par identifiant (`df_final.groupby("id_abonne").size()`), mesurant la fréquence des abonnements par utilisateur; Période d'essai (`df_final["periode_essai"]`), indiquant la durée des essais gratuits. Tarif total estimé (`df_final["tarif_total_estime"]`), représentant le coût prévu pour chaque abonnement et Durée de l'offre promotionnelle (`df_final["duree_promo_mois"]`), indiquant la période pendant laquelle une réduction est appliquée.

Pour chaque variable, plusieurs mesures statistiques sont calculées :

- Moyenne (`serie.mean()`), donnant la valeur centrale en additionnant toutes les observations et en divisant par leur nombre.

- Médiane (`serie.median()`), représentant la valeur centrale qui sépare la distribution en deux parties égales.
- Variance (`serie.var()`), mesurant la dispersion des valeurs en calculant la moyenne des écarts quadratiques par rapport à la moyenne.
- Écart-type (`serie.std()`), représentant la racine carrée de la variance, utilisé pour interpréter la variabilité des données.
- Valeurs minimales et maximales (`serie.min()` et `serie.max()`), identifiant les bornes des distributions.
- Q1 (`serie.quantile(0.25)`) : valeur en dessous de laquelle se trouve 25 % des données.
- Q2 (`serie.quantile(0.50)`) : équivalent à la médiane.
- Q3 (`serie.quantile(0.75)`) : valeur sous laquelle se trouvent 75 % des données.

5. ANALYSE EXPLORATOIRE

L'analyse exploratoire permet de comprendre les dynamiques des abonnements à travers des segmentations pertinentes, en mettant en évidence les tendances, corrélations et comportements récurrents. Cette section décrit les segmentations effectuées, les insights majeurs et la raison pour laquelle ces analyses ont été choisies.

5.1 Évolution temporelle des abonnements

- *Méthodologie :*

Agrégation des abonnements par mois et année (`groupby(df_final["date_debut"].dt.to_period("M"))`) et conversion en format datetime. Calcul du taux de croissance mensuel via `pct_change() * 100`.

- *Objetif :*

Identifier les tendances d'évolution du nombre d'abonnements, détecter les pics et chutes, et repérer d'éventuels effets saisonniers ou impacts de campagnes promotionnelles.

- *Analyse des résultats :*

On observe une croissance rapide en juillet (+66,7 %) et août 2021 (+2380 %), suivie d'une légère baisse en septembre (-12,9 %) et d'un rebond en octobre (+58,3 %). Une explosion des abonnements est constatée en novembre (+76 %), suggérant une phase de recrutement massif, avant une chute marquée en décembre (-46,8 %) et janvier 2022 (-56,9 %). Un effet de relance est visible en février (+89,4 %) et mars 2022 (+170,4 %), avant une baisse drastique en juin (-78 %).

- *Insights clé:*

La forte dépendance aux campagnes promotionnelles est évidente, avec des périodes de forte acquisition suivies de pics de désabonnement. Une stratégie de rétention doit être mise en place après les périodes de recrutement massif pour stabiliser la base d'abonnés et limiter le churn post-promotion.

5.2 Taux de renouvellement des abonnements

- *Méthodologie :*

Comptage des abonnements par id_abonne, puis agrégation selon le nombre d'abonnements souscrits (groupby("Nombre d'abonnements")). Calcul du taux de renouvellement en divisant le nombre de clients par le total (Taux de renouvellement (%)).

- *Objetif :*

Évaluer la fidélité des abonnés et déterminer la proportion de clients qui souscrivent plusieurs abonnements.

- *Analyse des résultats :*

La majorité des clients (80,1 %) ont souscrit à trois abonnements ou plus, tandis que 15,2 % sont des abonnés uniques et 4,8 % ont renouvelé une seule fois. Le nombre moyen d'abonnements par client est de 2,65.

- *Insights clé:*

La base client est relativement stable, mais la proportion d'abonnés uniques est significative. Un programme de fidélisation ou des offres ciblées pourraient inciter ces clients à renouveler leur abonnement.

5.3 Impact des promotions sur le tarif moyen

- *Segmentation :*

Calcul de la moyenne des tarifs estimés (tarif_total_estime) en fonction de la durée de la promotion (duree_promo_mois).

- *Objetif :*

Mesurer l'effet des promotions sur le tarif final payé par les abonnés et analyser leur rentabilité.

- *Analyse des résultats :*

Plus la durée promotionnelle est longue, plus le tarif moyen mensuel augmente. Pour les abonnements sans promotion, le tarif moyen est de 0 €. Il passe à 0,93 €/mois pour 1 mois de promotion, 5,60 €/mois pour 2 mois et 47,72 €/mois pour 12 mois. Une corrélation très forte (0,99) est observée entre la durée promotionnelle et le tarif estimé.

- *Insights clé:*

Bien que les promotions à long terme entraînent un tarif moyen plus élevé, leur impact sur la rétention doit être analysé. Il est essentiel d'évaluer si ces abonnés restent après la période promotionnelle.

5.4 Segmentation des clients par fidélité

- *Méthodologie :*

Classification des abonnés en "Nouveau client" (1 abonnement) et "Client de passage" (>1 abonnement). Calcul de la durée moyenne d'abonnement et de la proportion de chaque segment.

- *Objetif:*

Identifier les différents profils d'abonnés et adapter les stratégies marketing en fonction de leur comportement.

- *Analyse des résultats :*

84,8 % des abonnés sont des clients de passage avec une durée moyenne d'abonnement de 2,94 abonnements. En revanche, 15,2 % des abonnés sont de nouveaux clients avec une seule souscription.

- *Insights clé:*

La forte proportion de clients de passage suggère une fidélité relativement faible. Des stratégies doivent être mises en place pour transformer les nouveaux clients en abonnés réguliers, notamment via des offres d'engagement prolongé.

5.5 Répartition des abonnements par tarif total estimé

- *Méthodologie :*

Comptage des abonnements en fonction de leur tarif total (groupby("tarif_total_estime")).

- *Objetif:*

Comprendre la répartition des abonnés en fonction des montants payés.

- *Analyse des résultats :*

396 abonnements sont totalement gratuits (0 €), tandis que 3526 abonnements ont un tarif moyen de 0,93 €. À mesure que le tarif augmente, le nombre d'abonnés diminue. Seulement 22 abonnements sont facturés à 21,84 € et 58 abonnements atteignent 47,72 €.

- *Insights clé:*

La majorité des abonnés bénéficient d'offres très attractives. Si l'objectif est d'augmenter la rentabilité, il faudrait revoir la stratégie tarifaire ou mettre en place des incitations à souscrire à des offres plus coûteuses.

5.6 Corrélation entre tarif total estimé et durée de promotion

- *Méthodologie :*

Calcul du coefficient de corrélation entre `tarif_total_estime` et `duree_promo_mois` (`df_final[["tarif_total_estime", "duree_promo_mois"]].corr()`).

- *Objetif:*

Vérifier s'il existe une relation linéaire entre la durée promotionnelle et le tarif final payé par les abonnés.

- *Analyse des résultats :*

Un coefficient de 0,99 indique une corrélation quasi-parfaite entre la durée promotionnelle et le tarif estimé, confirmant que les offres avec promotion plus longue génèrent un tarif moyen plus élevé.

- *Insights clé:*

Cette forte corrélation montre que les abonnés acceptent des tarifs plus élevés lorsqu'une promotion est appliquée sur une longue période. Une analyse plus approfondie est nécessaire pour mesurer l'impact sur la fidélisation.

5.7 Relation entre type d'offre et nombre d'abonnés

- *Méthodologie :*

Regroupement des abonnés par type d'offre (`groupby("type_offre").size()`) et calcul de la proportion de chaque segment.

- *Objetif:*

Évaluer la répartition des abonnés selon le type d'offre souscrite.

- *Analyse des résultats :*

La majorité des abonnés (55,7 %) ont souscrit à une offre FIL ROUGE, suivis de 38 % pour une offre PROMO, et seulement 6,2 % pour des offres classées comme Autre.

- *Insights clé:*

es offres promotionnelles attirent une part importante des abonnés, mais il est essentiel d'analyser leur fidélisation après la fin de la promotion. Une stratégie de transition vers des offres sans réduction pourrait être envisagée.

6. ANALYSE INFERENCIELE

6.1 Test du Khi^2 pour dépendance catégorielle

- *Méthodologie :*

Le test du Khi^2 est utilisé pour analyser la relation entre le type d'offre et la durée de permanence des abonnés. Une table de contingence est créée avec `pd.crosstab()`, regroupant les abonnements par type d'offre et par catégorie de permanence (<1 mois, 1-3 mois, 3-6 mois, 6-12 mois, >1 an). Ensuite, le test Khi^2 (`chi2_contingency()`) est appliqué pour calculer la statistique de test et la p-valeur associée.

- Objectif :

Ce test vise à déterminer si la durée d'abonnement dépend du type d'offre souscrit ou si ces deux variables sont indépendantes.

- Résultats :

Le test retourne une statistique Khi^2 de 5933 avec une p-valeur de 0.000, indiquant une dépendance significative entre les deux variables.

- Inférences :

Il existe une forte association entre le type d'offre et la durée de l'abonnement. Certaines offres retiennent mieux les abonnés que d'autres, ce qui peut refléter une politique commerciale efficace sur certaines formules, tandis que d'autres types d'offres sont plus fréquemment associés à des durées courtes.

6.2 Test de Fisher pour la comparaison de proportions

- *Méthodologie :*

Le test exact de Fisher est utilisé pour comparer la probabilité de renouvellement entre les abonnés ayant bénéficié d'une promotion et ceux ayant souscrit sans promotion. Une matrice de contingence est construite en comptant le nombre d'abonnés uniques et le nombre total

d'abonnements dans chaque catégorie (promo vs sans promo). Le test (`fisher_exact()`) calcule un odds ratio et une p-valeur.

- Objectif :

L'objectif est de mesurer l'impact des promotions sur la rétention et d'identifier si elles influencent significativement la probabilité de renouvellement.

- Résultats :

Le test retourne un odds ratio de 0.416 avec une p-valeur de 0.000, indiquant une différence significative.

- Inférences :

Les abonnés ayant souscrit via une promotion ont **59 %** de chances en moins de se réabonner que ceux sans promotion. Cela suggère que les promotions attirent un public plus opportuniste, avec un engagement moindre à long terme.

6.3 Analyse des tendances avec Theil-Sen et régression linéaire

- Méthodologie :

L'évolution du nombre d'abonnements est modélisée via une régression robuste de Theil-Sen (`theilslopes()`) et une régression linéaire classique (`linregress()`). Ces méthodes permettent de détecter une tendance significative tout en étant résistantes aux valeurs aberrantes.

- Objectif :

L'objectif est d'identifier si le nombre d'abonnements suit une tendance haussière ou baissière au fil du temps.

- Résultats :

La pente estimée par Theil-Sen est de +63,8 abonnements/mois avec un intervalle de confiance large (-11,2 à 116,8). La régression linéaire donne une pente de +51,1 abonnements/mois avec une p-valeur de 0.049, indiquant une tendance statistiquement significative.

- Inférences :

Bien que la tendance soit globalement positive, la forte variabilité montre que des facteurs externes influencent significativement les résultats. L'augmentation du nombre d'abonnés n'est pas linéaire et semble fortement corrélée aux campagnes de recrutement.

6.4 Modélisation probabiliste du churn avec une chaîne de Markov

- *Méthodologie :*

Une chaîne de Markov a été construite en utilisant la bibliothèque numpy. Elle modélise la Les abonnés sont classés en deux états : Actif (encore abonné) et Résilié (churn). Une matrice de transition est construite pour estimer la probabilité de passer d'un état à l'autre sur plusieurs cycles.

- *Objectif :*

Le but est d'évaluer l'évolution de la base d'abonnés et d'anticiper le churn futur en fonction des tendances observées.

- *Résultats :*

Probabilité qu'un abonné reste actif : 94,1 %, Probabilité qu'un abonné résilie : 5,9 %; Probabilité qu'un ancien abonné revienne : 4,0 %; Après 3 cycles, 40,5 % des abonnés restent actifs et 59,5 % sont résiliés.

- *Inférences :*

Sans nouvelles acquisitions, la base d'abonnés diminue progressivement. La fidélisation est donc essentielle pour maintenir la stabilité et compenser le churn naturel.

6.5 Comparaison des nouveaux abonnés vs churn estimé dans le temps

- *Structure :*

Pour comparer l'évolution des nouveaux abonnés et du churn estimé dans le temps, une analyse temporelle a été réalisée à l'aide des bibliothèques pandas, matplotlib et seaborn. Dans le code, les étapes suivantes ont été effectuées :

1. Agrégation des abonnements par semaine en utilisant `df_final.groupby("Semaine").size()`.
2. Estimation du churn : il a été supposé qu'environ 15% des abonnés se désabonnent après 3 semaines, ce qui a été implémenté avec `df_tendance["Churn estimé"] = df_tendance["Nombre d'abonnements"].shift(3) * 0.15`.
3. Calcul de la croissance nette : différence entre les nouveaux abonnés et le churn estimé.
4. Visualisation : un graphique linéaire a été créé avec `seaborn.lineplot()` pour représenter les nouveaux abonnés, le churn estimé et la croissance nette.

- Objectif :

L'objectif de cette analyse est de visualiser l'évolution du parc d'abonnés, en identifiant les tendances de croissance et les périodes où le churn devient un facteur critique. Cette comparaison permet d'évaluer si la stratégie d'acquisition compense les pertes dues aux désabonnements.

- Résultats :

Une hausse irrégulière du nombre d'abonnés avec des pics périodiques. Un churn relativement stable, mais légèrement croissant avec le temps. Une croissance nette fluctuante, indiquant que certaines périodes d'acquisition sont plus performantes que d'autres.

- Inférences :

La croissance du parc d'abonnés est positive dans l'ensemble, mais montre des variations importantes en fonction des campagnes. L'augmentation progressive du churn suggère qu'il y a une part des abonnés qui ne restent pas fidèles sur le long terme. L'analyse met en évidence l'importance de maintenir une acquisition régulière d'abonnés pour éviter une décroissance nette lorsque le churn devient dominant. Il pourrait être pertinent d'étudier plus en détail les causes du churn, en segmentant les abonnés selon leur type d'offre et leur engagement.

6.6 Projection linéaire de la croissance des abonnements

- *Structure :*

Une régression linéaire a été réalisée avec `sklearn.linear_model.LinearRegression()`, en utilisant les tendances historiques des abonnements pour prédire leur évolution future.

- Objectif :

Estimer le nombre d'abonnements dans les prochaines semaines en supposant que la tendance actuelle se poursuit.

- Résultats :

La projection linéaire montre une croissance modérée des abonnements dans les 12 semaines suivantes. La stabilité de cette croissance dépend des efforts marketing et des conditions du marché.

- Inférences :

L'augmentation projetée est positive, mais des facteurs externes (campagnes, promotions) peuvent modifier cette tendance. Le suivi des données réelles permettra d'affiner ces prédictions.

6.7 Seuil minimal pour stabiliser la base d'abonnés

- *Méthodologie :*

Le churn moyen par semaine est estimé à partir des tendances passées. Le seuil de stabilisation est déterminé en identifiant le nombre d'abonnements nécessaires pour compenser ces pertes.

- *Objectif :*

Évaluer combien de nouveaux abonnements doivent être acquis chaque semaine pour éviter la décroissance de la base d'abonnés.

- *Résultats :*

Le churn moyen hebdomadaire est estimé à 3 abonnements/semaine, ce qui signifie que ce volume doit être atteint pour stabiliser la base.

- *Inférences :*

Une acquisition inférieure à 3 abonnés par semaine entraînerait une décroissance inévitable de la base. Il est donc impératif de maintenir un flux constant de nouveaux abonnés pour assurer une stabilité à long terme.

7. EXPORTATION ET PARTAGE DES DONNÉES

L'exportation des données est réalisée via la bibliothèque `gsread`, permettant l'interaction avec Google Sheets. Pour garantir l'accès, une authentification auprès de Google Drive est d'abord effectuée avec `auth.authenticate_user()`, suivie de l'obtention des credentials via `default()`, qui sont ensuite utilisés pour autoriser `gsread`.

Une fois l'authentification établie, le script vérifie si le fichier Google Sheets nommé "Abonnements_Paris_Match" existe déjà. S'il est introuvable (`SpreadsheetNotFound`), il est automatiquement créé avec `gc.create(nom_fichier)`. Ensuite, la première feuille de calcul est sélectionnée. Si aucune feuille n'est disponible, une nouvelle est générée avec une structure par défaut (`rows="1000", cols="20"`).

Avant l'envoi des données, une conversion des dates est appliquée. Étant donné que les colonnes de type `datetime` peuvent provoquer des erreurs lors de l'exportation en JSON, elles sont transformées en chaînes de caractères via `df[col] = df[col].astype(str)`. Ensuite, le `DataFrame` est converti en une liste de listes, le premier élément contenant les noms des colonnes, et les lignes suivantes contenant les valeurs converties en `str`.

L'écriture des données dans Google Sheets se fait via `worksheet.update(values=data, range_name="A1")`, qui remplace tout le contenu de la feuille avec les nouvelles valeurs formatées. Une fois les données mises à jour, le fichier est partagé en mode lecture publique (`sh.share("", perm_type="anyone", role="reader")`) afin qu'il puisse être utilisé dans Looker Studio.

Si aucune erreur ne survient, le script affiche un message confirmant le succès de l'opération avec un lien direct vers le fichier. En cas d'échec, une exception est capturée et un message d'erreur est affiché, précisant la cause du problème. Cette approche assure une exportation fluide et sans erreur des données traitées vers Google Sheets pour analyse et visualisation externe.

8. DATAVIZ LOOKER

8.1 KPIs et vue d'ensemble

L'interface Looker permet de visualiser les principaux indicateurs de performance du parc d'abonnements, facilitant l'analyse des tendances et de la segmentation client. La vue d'ensemble repose sur des indicateurs clés sous forme de cartes de KPI et diagrammes circulaires. Les métriques principales incluent :

- Nombre total d'abonnés : visualisé sous forme d'un KPI numérique affichant la valeur agrégée.
- Revenu cumulé : représenté également par un KPI numérique calculé à partir du tarif mensuel et de la durée d'abonnement.
- Revenu moyen par abonné : obtenu par la division du revenu total par le nombre d'abonnés actifs.
- Tarif moyen des offres : visualisé par un indicateur de moyenne pondérée, illustrant la diversité des prix des abonnements.
- Répartition des abonnés par type d'offre : affichée via un diagramme circulaire, mettant en évidence la proportion des abonnés sous des offres promotionnelles, fil rouge ou indéterminées.
- Répartition des abonnés par levier d'acquisition : représentée par un diagramme en barres horizontales, distinguant les canaux d'acquisition tels que kiosque, paywall, newsletters, push notifications et opérations éditoriales.

8.2 Séries temporelles

L'évolution du parc d'abonnements est représentée au travers de plusieurs graphiques de séries temporelles, permettant une lecture détaillée de la dynamique du portefeuille clients. Les principales analyses comprennent :

- Évolution du nombre d'abonnés dans le temps : illustrée par un graphique linéaire, où l'axe des abscisses représente le temps (année et mois) et l'axe des ordonnées indique le nombre d'abonnés actifs.
- Variation du tarif : visualisée avec un graphique en courbe, mettant en relation les fluctuations du tarif moyen au fil du temps.
- Croissance des abonnements par levier : affichée sous forme de graphe en barres empilées, permettant d'identifier les canaux d'acquisition les plus performants sur des périodes spécifiques.
- Corrélation entre le tarif mensuel et la période d'essai : illustrée par un nuage de points, permettant de mesurer l'impact des promotions sur les abonnements à long terme.
- Relation entre moyen d'abonnement et période d'essai : affichée sous forme d'un histogramme classifiant les abonnés selon la durée de leur engagement.

Ces visualisations permettent une analyse des tendances de croissance, des fluctuations tarifaires et des modes de consommation, offrant ainsi un aperçu stratégique sur la stabilité du portefeuille d'abonnés.

8.3 Tableau pour exportation

Le tableau de données exportable dans Looker permet d'assurer une compatibilité avec d'autres outils analytiques et d'effectuer des traitements externes plus poussés. Il est structuré sous forme d'un tableau plat, où chaque ligne représente un abonnement unique. L'exportation de ce tableau permet une exploitation avancée des données pour des analyses complémentaires et des modélisations prédictives.

9. STRATÉGIES BUSINESS, SCALABILITÉ ET ACTIONS À VENIR

9.1 Collecte de nouvelles données pour enrichir l'analyse

Nom	Description	Éléments associés
<i>Coût d'Acquisition Client (CAC)</i>	Collecte des coûts publicitaires par canal pour relier les dépenses aux abonnements générés.	CAC par canal, CAC moyen, ROI des campagnes
<i>Impact des campagnes marketing</i>	Tracking des interactions abonnés avec les offres et canaux d'acquisition.	Taux de conversion par canal, attribution multi-touch, uplift marketing
<i>Motifs de résiliation</i>	Intégration d'enquêtes clients et de motifs de désabonnement pour enrichir l'analyse du churn.	Classification des motifs de churn, score de churn basé sur feedback client

<i>Engagement des abonnés</i>	Mesure des interactions des abonnés avec les contenus et services digitaux.	Score d'engagement, fréquence d'interaction, segmentation comportementale
<i>Données socio-démographiques</i>	Analyse fine du profil des abonnés pour affiner la segmentation.	Segmentation avancée (âge, localisation, CSP), corrélation avec la rétention
<i>Cycle de vie de l'abonné</i>	Suivi des périodes d'essai, reconductions et désabonnements.	Taux de conversion essai - abonnement, durée moyenne de rétention

9.2 Approfondissement de l'analyse via de nouvelles métriques

Nom	Description	Éléments associés
<i>Modèle prédictif de churn</i>	Exploitation de l'historique abonnés pour prédire les risques de désabonnement.	Score de churn, probabilité de churn, facteurs influents
<i>Segmentation des abonnés à risque</i>	Détection des groupes les plus exposés au churn en fonction des patterns comportementaux.	Profil des abonnés à risque, rétention par segment
<i>Lifetime Value (CLV)</i>	Calcul de la valeur financière attendue d'un abonné en fonction de son cycle de vie.	CLV par segment, CLV ajusté au churn, contribution nette par abonné
<i>Élasticité aux promotions</i>	Analyse de la sensibilité aux réductions pour optimiser la stratégie tarifaire.	Taux de conversion promo - abonnement, impact des réductions sur la fidélisation
<i>Effet des changements d'offre</i>	Mesure de l'impact des upgrades/downgrades sur la rentabilité et la rétention.	Taux de migration, impact sur le CLV, taux de re-désabonnement post-migration

9.3 Gouvernance et récupération des données

Nom	Description	Éléments associés
<i>Standardisation des nomenclatures</i>	Définition d'une convention de nommage claire et cohérente pour les bases de données et leurs champs, facilitant la compréhension et l'exploitation des jeux de données.	Préfixes métiers (tb_marketing_*, tb_subscriptions_*), suffixes explicites (_historique, _current), standardisation des noms (CD_CLIENT, DT_ABONNEMENT).

<i>Organisation sémantique</i>	Structuration des bases en fonction des domaines métier pour éviter les ambiguïtés et améliorer la navigation des données.	Catégorisation (tb_marketing_subscribers_origins, tb_revenue_subscriptions_cycles), séparation des données transactionnelles et analytiques.
<i>Dictionnaire de données</i>	Documentation centralisée des schémas des bases, types de données, relations et définitions des indicateurs clés.	Table de métadonnées (tb_metadata_dictionary), accès partagé aux équipes data, mise à jour automatisée des nouveaux champs.
<i>Contrôle des valeurs et type</i>	Vérification systématique de la typologie des colonnes pour garantir leur conformité et éviter les erreurs de traitement.	SAudit des formats (DT_* en datetime, CD_* en string), contrôle des conversions (float64 → decimal).
<i>Validation et traçabilité des transformations</i>	Mise en place d'un suivi des modifications et d'un versioning des données pour garantir leur intégrité historique.	Journaux de transformation (tb_log_etl), suivi des mises à jour (DT_MODIFICATION).

9.4 Automatisation et industrialisation

Nom	Description	Éléments associés
<i>Pipeline ETL scalable</i>	Automatisation de la collecte et du traitement via un pipeline robuste (ex: Airflow, dbt).	Temps de traitement, latence de mise à jour, fréquence d'actualisation
<i>Reporting dynamique</i>	Mise en place d'un tableau de bord avec mise à jour en temps réel des métriques clés.	Indicateurs temps réel, taux d'actualisation des données
<i>Intégration d'alertes analytiques</i>	Détection automatique des anomalies et envoi de notifications.	Anomalies détectées, fréquence des alertes, temps de réaction
<i>Infrastructure scalable</i>	Proposition d'une architecture flexible et performante pour supporter la croissance.	Temps de réponse des requêtes, coût d'infrastructure, capacité de montée en charge
<i>Personnalisation des recommandations</i>	Implémentation d'un moteur de recommandation basé sur le profil utilisateur.	Taux d'adoption des recommandations, impact sur le churn, engagement moyen post-reco